Fine-tuning de T5 para generación automática de resúmenes de texto sobre el dataset CNN/DailyMail

Aarón Ulises Santillán Huamán
20200445
a20200445@pucp.edu.pe

Leoncio Percy Huamán López
20191833
a20191833@pucp.edu.pe

Rodrigo Jose Valle Saavedra
20210680
valle.rodrigo@pucp.edu.pe

Joseph Álvaro Tintaya Marce
20201155
a20201155@pucp.edu.pe

***Resumen*—Los modelos de lenguaje basados en arquitecturas Transformer han transformado de manera significativa las tareas de procesamiento de lenguaje natural (NLP), destacando en aplicaciones como traducción automática, respuesta a preguntas y resumen de texto. En este proyecto se aborda la tarea de generación automática de resúmenes *abstractive* utilizando el modelo T5 (*Text-to-Text Transfer Transformer*) sobre el dataset CNN/DailyMail, ampliamente empleado como *benchmark* en la comunidad científica. En este trabajo se describe la implementación del *fine-tuning* de la variante t5-small usando la librería Hugging Face Transformers. Se detalla la selección de un subconjunto del dataset, el preprocesamiento y tokenización de los ejemplos, la configuración de entrenamiento y el pipeline de evaluación mediante métricas ROUGE. Además, se deja establecido el procedimiento experimental completo para su reproducción y extensión.**

***Index Terms*—Deep Learning, Procesamiento de Lenguaje Natural, Resumen Automático, T5, CNN/DailyMail, Transformers, ROUGE.**

I. Introducción

Los modelos de lenguaje de gran escala basados en la arquitectura Transformer se han consolidado como la base de muchas de las soluciones actuales en procesamiento de lenguaje natural (NLP). A diferencia de enfoques anteriores basados en redes recurrentes (RNN) o LSTM, los transformers permiten modelar dependencias de largo alcance de manera más eficiente y paralelizable, logrando resultados de estado del arte en múltiples tareas.

Una de las problemáticas más relevantes a la cual estos modelos dan solución es el resumen automático de texto, cuyo objetivo es condensar documentos extensos en versiones breves y coherentes, preservando la información esencial. En particular, el resumen *abstractive* requiere que el modelo genere nuevas oraciones que reexpresen el contenido clave, en lugar de limitarse a extraer fragmentos del texto original.

Este problema es especialmente desafiante dentro del aprendizaje automático, pues exige que el modelo no solo comprenda el contenido del texto, sino que además sea capaz de sintetizarlo, parafrasearlo y mantener coherencia semántica sin generar información incorrecta.

El modelo T5 (*Text-to-Text Transfer Transformer*), propuesto por Raffel et al. [1], plantea un paradigma unificado donde todas las tareas de NLP se formulan como problemas de entrada-salida en formato texto a texto. Bajo este enfoque, el resumen automático se implementa como una transformación de un documento largo en un resumen corto precedido por un prefijo de tarea como *"summarize:"*. Esta unificación facilita el uso de una misma arquitectura para tareas diversas como traducción, clasificación, respuesta a preguntas y resumen.

El dataset CNN/DailyMail es uno de los conjuntos de datos más utilizados para evaluar modelos de resumen *abstractive*. Contiene cientos de miles de artículos de noticias en inglés acompañados de resúmenes humanos (*highlights*), y se ha empleado para comparar arquitecturas como BERT, BART, PEGASUS y T5 utilizando métricas ROUGE.

En este contexto, el presente trabajo tiene como objetivo implementar y documentar el *fine-tuning* de la variante t5-small sobre el dataset CNN/DailyMail utilizando la librería Hugging Face. En este, se describe la configuración experimental concreta, el preprocesamiento de datos, el esquema de entrenamiento y el pipeline de evaluación, así como ejemplos de resúmenes generados por el modelo ajustado. El objetivo de este estudio es desarrollar, entrenar y evaluar un sistema de resumen automático basado en T5-small aplicado a CNN/DailyMail, analizando su rendimiento mediante métricas ROUGE e identificando sus principales limitaciones.

El resto del documento se organiza de la siguiente manera: en la Sección II se presenta el estado del arte; en la Sección III se describe el dataset CNN/DailyMail; en la Sección IV se resume el modelo base T5; en la Sección V se detalla la metodología e implementación del *fine-tuning*; en la Sección VI se discute el esquema de evaluación y resultados preliminares; en la Sección VII se presenta la discusión; y finalmente, en la Sección VIII se presentan las conclusiones y el trabajo futuro.

II. Estado del Arte

II-A. Paradigma text-to-text y modelo T5

Raffel et al. [1] introducen el modelo T5 y proponen reformular las tareas de NLP bajo un paradigma unificado

de entrada-salida textual. En lugar de diseñar arquitecturas específicas para cada tarea, T5 trata todas las entradas y salidas como cadenas de texto y utiliza prefijos que indican explícitamente la tarea (*"translate English to German:"*, *"summarize:"*, etc.). Tras un preentrenamiento masivo sobre el corpus C4 (*Colossal Clean Crawled Corpus*), el modelo puede ajustarse con *fine-tuning* a tareas específicas alcanzando resultados competitivos en múltiples *benchmarks*, incluyendo el resumen automático.

II-B. T5 en resumen de texto

Itsnaini et al. [2] aplican T5 a la generación de resúmenes de noticias en idioma indonesio. Mediante *fine-tuning* sobre un conjunto de datos periodístico, muestran que el modelo supera a enfoques basados en RNN y LSTM en métricas ROUGE-1, ROUGE-2 y ROUGE-L, alcanzando valores superiores a 0.6. Este resultado respalda el uso de T5 como modelo base para tareas de resumen y motiva su aplicación al dataset CNN/DailyMail en este proyecto.

II-C. Inconsistencia factual en resumen abstractive

Huang et al. [3] analizan el problema de la inconsistencia factual en resúmenes generados automáticamente, es decir, cuando el modelo introduce información incorrecta, no respaldada o distorsionada respecto al texto original. El trabajo revisa métodos para detectar y mitigar estos errores, incluyendo modelos auxiliares de verificación factual y estrategias de entrenamiento. Este aspecto es relevante para el presente proyecto, ya que uno de los objetivos a mediano plazo es evaluar no solo la calidad léxica de los resúmenes, sino también su fidelidad factual.

II-D. Revisión del estado del arte en resumen abstractive

Nnadi y Bertini [4] ofrecen una revisión exhaustiva del campo de la generación de resúmenes *abstraective*. El artículo discute modelos preentrenados como T5, BART, PEGASUS y GPT-3, así como los datasets más utilizados (CNN/DailyMail, XSum, SAMSum, entre otros) y las principales métricas de evaluación (ROUGE, BLEU, METEOR, BERTScore). Además, señala desafíos abiertos como la inconsistencia factual, la adaptación a dominios específicos y la necesidad de métricas que capturen mejor la coherencia y la fidelidad semántica. Este contexto permite posicionar el presente trabajo dentro de la literatura vigente.

III. Descripción del dataset CNN/DailyMail

III-A. Características generales

El dataset CNN/DailyMail, introducido por Hermann et al. (2015), contiene artículos de noticias en inglés procedentes de los portales CNN.com y DailyMail.co.uk, acompañados de resúmenes humanos en forma de *highlights*. Cada muestra incluye el texto completo de la noticia y un conjunto de frases cortas que sintetizan la información principal.

En este proyecto se utiliza la versión `3.0.0` del dataset disponible en la librería `datasets` de Hugging Face. De manera resumida, las características principales se muestran en el Cuadro I.

Cuadro I
Resumen de características del dataset CNN/DailyMail

Característica	Valor aproximado
Idioma	Inglés
Número total de muestras	∼311 000 artículos
Particiones estándar	287 113 (entrenamiento)
	13 368 (validación)
	11 490 (prueba)
Fuentes	CNN.com y DailyMail.co.uk
Tarea principal	Resumen *abstractive*
Métricas típicas	ROUGE-1, ROUGE-2, ROUGE-L

III-B. Campos más relevantes

Cada registro del dataset contiene información textual y metadatos. En este proyecto se emplean principalmente los campos resumidos en la Tabla II.

Cuadro II
Principales campos del dataset CNN/DailyMail

Campo	Descripción
`id`	Identificador único de la noticia.
`article`	Texto completo de la noticia.
`highlights`	Resumen corto elaborado por editores humanos.
`source`	Medio de origen (CNN o DailyMail), presente en algunas versiones.
`URL`	En algunas variantes, contiene la URL original del artículo (eliminada en versiones más recientes por privacidad).
`Date`	Fecha de publicación del artículo (no presente en el dataset base).

En promedio, los artículos contienen alrededor de 760 palabras, mientras que los resúmenes tienen unas 55 palabras (aproximadamente tres oraciones). Esta diferencia hace que el dataset sea apropiado para estudiar la capacidad de los modelos de generar resúmenes condensados pero informativos.

IV. Descripción del modelo base T5

El modelo T5 se basa en una arquitectura *encoder-decoder* con bloques Transformer tanto en el codificador como en el decodificador [1]. El encoder recibe el texto de entrada y lo transforma en una representación contextual, mientras que el decoder genera secuencialmente la salida atendiendo a la representación codificada y al texto generado previamente. Esta arquitectura se puede visualizar en la Figura 1.

Durante su preentrenamiento, T5 emplea una tarea de "corrupción de spans", donde fragmentos del texto original son reemplazados por marcadores, y el modelo debe predecir las secuencias faltantes. Este esquema favorece la comprensión contextual y mejora la capacidad de generación de texto fluido. Adicionalmente, el uso de prefijos de tarea (*task prefixing*) permite indicar qué operación debe realizar el modelo sin modificar su arquitectura.

En este proyecto se utiliza la variante `t5-small`, que presenta un tamaño moderado en términos de número de parámetros y resulta adecuada para experimentos en entornos como Google Colab, donde los recursos computacionales son limitados.

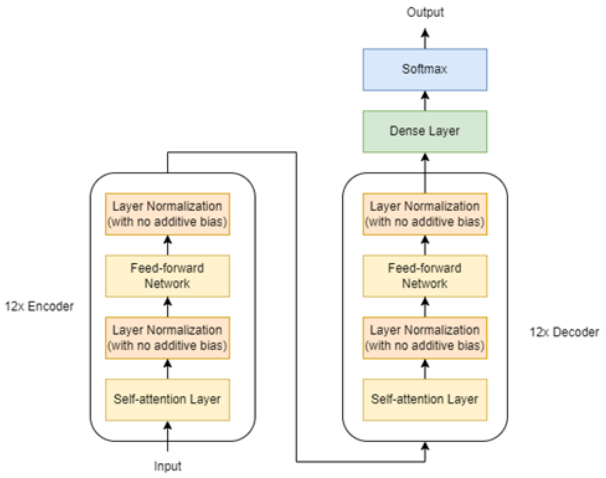


Figura 1. Arquitectura general del modelo T5 (versión base). Imagen adaptada de [5].

V. Metodología e implementación del fine-tuning

En esta sección se describe la implementación concreta del *fine-tuning* de T5 sobre CNN/DailyMail, siguiendo el flujo implementado en el cuaderno de trabajo.

V-A. Entorno de experimentación

Los experimentos se realizaron en un entorno basado en Google Colab, empleando GPU cuando estuvo disponible. Se utilizaron las siguientes librerías principales de Python:

- `transformers` (Hugging Face) para cargar el modelo T5, el tokenizador y el objeto `Trainer`.
- `datasets` (Hugging Face) para la carga y manipulación del dataset CNN/DailyMail.
- `evaluate` y `rouge_score` para el cálculo de las métricas ROUGE.
- `accelerate` para optimizaciones de entrenamiento en GPU.

Se fijó una semilla global (`seed = 42`) para PyTorch y NumPy con el objetivo de mejorar la reproducibilidad de los experimentos. El hardware típico empleado incluyó una GPU NVIDIA Tesla T4 de 16 GB, CPU virtualizada de Google Colab y aproximadamente 12 GB de memoria RAM, junto con Python 3.12, PyTorch y Transformers

V-B. Selección del subconjunto de datos

Dado el tamaño original del dataset, se trabajó con subconjuntos reducidos para hacer el entrenamiento manejable en el entorno disponible. A partir de la versión `3.0.0` de `cnn_dailymail`, se aplicaron las siguientes selecciones:

- Entrenamiento: se tomaron directamente 20 000 ejemplos del split de entrenamiento (`small_train`).
- Validación: se utilizaron 2 000 ejemplos completos del split de validación (`small_val`).
- Prueba: se consideraron también 2 000 ejemplos completos del split de prueba.

Esta reducción permite explorar configuraciones de entrenamiento y validar el pipeline sin incurrir en costos computacionales excesivos.

V-C. Preprocesamiento y tokenización

Cada ejemplo del dataset se convierte en un par entrada-salida adecuado para T5:

- Entrada: se construye el texto `"summarize: "` seguido del contenido del campo `article`.
- Salida: se utiliza directamente el campo `highlights`, que corresponde al resumen humano.

Se utilizó el tokenizador `T5TokenizerFast` asociado a `t5-small`, con los siguientes parámetros principales:

- Longitud máxima de entrada (`max_input_length`): 512 tokens.
- Longitud máxima de salida (`max_target_length`): 128 tokens.
- *Truncation* activado para cortar textos que superen la longitud máxima.
- *Padding* a longitud máxima tanto en entradas como en salidas.

Los `input_ids` y `attention_mask` se generan a partir de las entradas tokenizadas, mientras que las etiquetas (`labels`) se obtienen tokenizando los resúmenes. Para las etiquetas, el token de *padding* se sustituye posteriormente por el valor `-100`, de modo que no contribuya al cálculo de la pérdida.

El preprocesamiento se aplicó de forma batched mediante `map` de la librería `datasets`, removiendo las columnas originales del dataset y conservando únicamente los tensores necesarios para el entrenamiento.

V-D. Configuración de entrenamiento

El modelo base `t5-small` se cargó mediante `T5ForConditionalGeneration` y se movió al dispositivo disponible (`cuda` o `cpu`). Se habilitó *gradient checkpointing* para reducir el consumo de memoria en GPU durante el entrenamiento.

Para el entrenamiento se empleó el objeto `Trainer` de Hugging Face con los siguientes `TrainingArguments` principales:

- `output_dir = "./t5_cnn_summarization"` para almacenar el modelo ajustado.
- Número de épocas: `num_train_epochs = 3`.
- *Batch size* por dispositivo: `per_device_train_batch_size = 1`.
- *Gradient accumulation steps*: `gradient_accumulation_steps = 4`, logrando un *batch size* efectivo de 4.
- `learning_rate = 1e-4`.
- `optim = adafactor` como optimizador, recomendado para modelos T5.
- `fp16 = True` para entrenamiento en precisión mixta cuando se utiliza GPU.
- `weight_decay = 0.01`.

- Estrategia de guardado: `save_strategy = epoch`, guardando el modelo al final de cada época.
- `save_total_limit = 2` para limitar el número de checkpoints almacenados.
- `logging_steps = 100` para registrar el avance del entrenamiento.
- `remove_unused_columns = False` para asegurar compatibilidad con el formato de los datos.

En esta etapa experimental se optó por no realizar evaluación automática durante el entrenamiento (*evaluation during training*), concentrando la evaluación en una fase posterior dedicada. Para manejar los *batches* y el enmascaramiento adecuado de etiquetas se utilizó `DataCollatorForSeq2Seq`.

El modelo se entrenó ejecutando `trainer.train()`, y al finalizar se guardó el modelo ajustado en el directorio de salida especificado.

V-E. Pipeline general del proyecto

El flujo de trabajo del proyecto puede resumirse en las siguientes etapas:

- Carga y particionado del dataset CNN/DailyMail.
- Preprocesamiento y tokenización de artículos y resúmenes.
- Entrenamiento del modelo T5-small mediante *fine-tuning*.
- Generación de resúmenes
- Evaluación cuantitativa con métricas ROUGE.
- Generación de resultados y análisis.

La Figura 2 ilustra el pipeline general seguido en el proyecto.

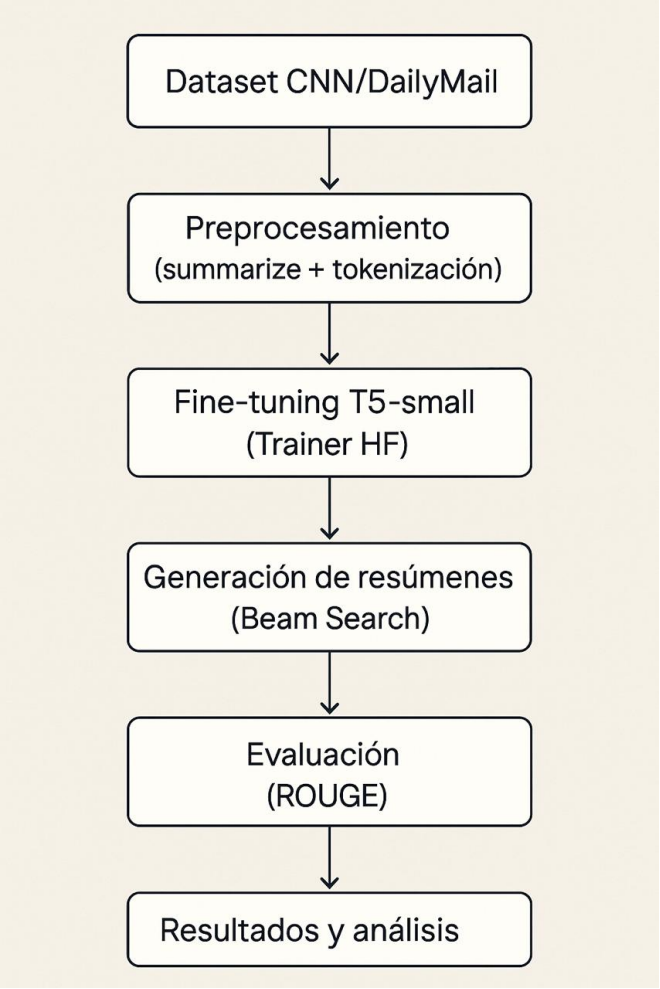


Figura 2. Pipeline general del proyecto: carga del dataset, preprocesamiento, tokenización, entrenamiento, evaluación y generación de resúmenes.

V-F. Pipeline de evaluación

Para la evaluación, se recargó el modelo entrenado desde `./t5_cnn_summarization` junto con el tokenizador. En esta fase se utilizó nuevamente la partición de validación completa del dataset CNN/DailyMail.

El procedimiento seguido fue el siguiente:

- Construcción de las entradas: para cada noticia de validación se generó el texto `"summarize: " + article`.
- Tokenización de las entradas con longitud máxima 512 y *padding* a longitud máxima.
- Tokenización de los *highlights* de referencia con longitud máxima 128.
- Construcción de tensores de `input_ids`, `attention_mask` y etiquetas (`labels`), sustituyendo el *padding* por `-100` en las etiquetas para que sea ignorado en el cálculo de la pérdida.
- Creación de un `DataLoader` con `batch_size = 8` para la generación y evaluación.

La generación de resúmenes se realizó mediante `model.generate()` empleando:

- `max_new_tokens = 80` como límite máximo para la longitud del resumen generado.
- `num_beams = 4` para búsqueda por *beam search*.
- `early_stopping = True` en la generación de ejemplos cualitativos.

Los resúmenes generados y los de referencia se decodificaron usando el tokenizador y se evaluaron mediante la métrica ROUGE disponible en la librería `evaluate`. Se calcularon las variantes más comunes (ROUGE-1, ROUGE-2, ROUGE-L, ROUGE-Lsum), obteniendo un conjunto de métricas que permiten cuantificar la calidad léxica de los resúmenes generados.

VI. Resultados preliminares y análisis cualitativo

VI-A. Esquema de métricas

El pipeline de evaluación descrito en la sección anterior permitió calcular automáticamente las métricas ROUGE sobre los 2 000 ejemplos del conjunto de validación. Estas métricas cuantifican la superposición léxica entre los resúmenes generados por el modelo y los resúmenes humanos de referencia. Los valores obtenidos se muestran en la Tabla III.

Cuadro III
MÉTRICAS ROUGE OBTENIDAS EN EL CONJUNTO DE VALIDACIÓN

Métrica	Valor (%)
ROUGE-1	39.79
ROUGE-2	18.55
ROUGE-L	28.38
ROUGE-L Sum	28.38

Estos resultados indican que el modelo logra capturar una parte significativa del contenido relevante del artículo original (ROUGE-1), aunque las coincidencias de bigramas (ROUGE-2) y la estructura general del resumen (ROUGE-L) muestran que aún existe espacio para mejorar la coherencia y fluidez del texto generado. Sin embargo, los valores obtenidos son consistentes con lo esperado para un modelo *t5-small* entrenado sobre un subconjunto reducido del dataset.

VI-B. Línea base y comparación con el estado del arte

Diversos estudios previos reportan resultados de referencia sobre el dataset CNN/DailyMail utilizando variantes del modelo T5. En particular, Raffel et al. [1] indican que T5-small alcanza valores aproximados de ROUGE-1 en el rango de 33 % a 38 %, mientras que arquitecturas más grandes como T5-base y T5-large suelen superar el 40 %.

En comparación, el modelo entrenado en este trabajo alcanzó ROUGE-1 = 39.79 %, ROUGE-2 = 18.55 % y ROUGE-L = 28.38 %, lo cual se encuentra alineado con lo esperado para T5-small entrenado con recursos limitados y un subconjunto del dataset original. Estos resultados sugieren que el pipeline implementado reproduce adecuadamente la calidad reportada en la literatura para modelos de tamaño similar.

VI-C. Resúmenes generados

Además del análisis cuantitativo, se implementó una función para generar resúmenes a partir de artículos individuales, permitiendo realizar una inspección cualitativa de los resultados. La función construye el prefijo `"summarize: "` seguido del artículo original y utiliza búsqueda por *beam search* para generar el resumen.

Al comparar el artículo original, el resumen humano (*highlights*) y el resumen generado por el modelo, se observa que:

- El modelo logra condensar adecuadamente la información más importante.
- La coherencia interna del resumen generado es, en general, aceptable.
- Existe un nivel moderado de parafraseo respecto al resumen humano.
- Algunas inconsistencias factuales menores pueden aparecer, lo cual coincide con lo reportado en la literatura.

Este análisis cualitativo complementa las métricas ROUGE y proporciona una visión más completa de las fortalezas y limitaciones del modelo entrenado.

VII. DISCUSIÓN

Los resultados obtenidos muestran que el modelo T5-small es capaz de capturar información relevante del artículo original, logrando valores competitivos de ROUGE para un entorno de entrenamiento limitado. No obstante, se identificaron ciertas limitaciones:

- **Inconsistencias factuales:** En algunos resúmenes generados se observaron detalles incorrectos o información no presente en el artículo, lo cual coincide con lo señalado por Huang et al. [3].
- **Pérdida de detalles importantes:** Debido a la compresión de texto, algunos elementos clave del artículo no son incluidos en el resumen generado.
- **Impacto del tamaño del modelo:** T5-small ofrece resultados razonables, pero publicaciones previas muestran que T5-base y T5-large logran una mayor calidad y coherencia global.
- **Dataset reducido:** El uso de un subconjunto de 20,000 ejemplos limita la capacidad del modelo de generalizar tan bien como los resultados reportados en la literatura con entrenamiento completo.

En conjunto, estos hallazgos permiten comprender la calidad del modelo y motivan mejoras en arquitectura, datos y criterios de evaluación, especialmente en términos de consistencia factual y cobertura de información relevante.

VIII. CONCLUSIONES Y TRABAJO FUTURO

En este trabajo se ha descrito la implementación del *fine-tuning* del modelo T5 (variante `t5-small`) sobre el dataset CNN/DailyMail utilizando la librería Hugging Face. Se detalló la selección de 20 000 ejemplos de entrenamiento y 2 000 de validación, reduciendo el tamaño original del dataset para permitir un entrenamiento viable en Colab. Asimismo, se explicó el proceso de preprocesamiento y tokenización, así como la configuración de entrenamiento que incluyó técnicas como *gradient accumulation*, *gradient checkpointing* y entrenamiento en precisión mixta.

La evaluación realizada sobre el conjunto de validación arrojó valores de ROUGE-1 = 39.79 %, ROUGE-2 = 18.55 % y ROUGE-L = 28.38 %. Estos resultados se encuentran dentro de lo esperado para un modelo de tamaño `t5-small` entrenado con recursos computacionales limitados y sobre un subconjunto del dataset original. Además, el análisis cualitativo mostró que el modelo es capaz de generar resúmenes coherentes y razonablemente informativos, aunque todavía presenta limitaciones en cuanto a fidelidad factual y preservación de detalles específicos.

Como trabajo futuro se plantea:

- Realizar entrenamientos adicionales para refinar los valores de ROUGE y mejorar la coherencia del resumen generado.
- Experimentar con variantes más grandes como `t5-base` o `t5-large`, siempre que los recursos lo permitan.
- Ejecutar análisis detallados de inconsistencias factuales y explorar técnicas para mitigarlas.
- Incorporar métricas basadas en similitud semántica, como BERTScore, para evaluar más profundamente la calidad del resumen.
- Integrar el modelo en una aplicación de uso real a través de una interfaz amigable para usuarios no técnicos.

IX. Demo en Hugging Face Spaces

Como parte del tercer entregable del curso, se desarrolló una aplicación interactiva con Gradio que permite generar resúmenes utilizando el modelo entrenado. La demo se encuentra publicada en Hugging Face Spaces y puede ser utilizada directamente desde un navegador web.

- **Demo en Hugging Face Spaces:** https://huggingface.co/spaces/Joseph1345/demo-ta-deeplearning

Esta interfaz permite probar el modelo con cualquier texto de entrada y visualizar el resumen generado en tiempo real.

X. Recursos del proyecto

Con el fin de facilitar la reproducción de los experimentos realizados y acceder al código fuente del proyecto, se ponen a disposición los siguientes enlaces:

X-A. Cuaderno de Google Colab

El cuaderno utilizado para la implementación completa del pipeline de *fine-tuning* del modelo T5 sobre el dataset CNN/DailyMail, incluyendo carga de datos, tokenización, entrenamiento, evaluación con ROUGE y generación de ejemplos, se encuentra disponible en:

- https://drive.google.com/file/d/1cJ9SN9FkMM7x6YlbOFUnXhGYU4UuLxa_/view?usp=sharing

X-B. Repositorio de GitHub

El repositorio oficial del proyecto contiene el código fuente organizado, los scripts utilizados, así como archivos complementarios relevantes para la ejecución del experimento:

- https://github.com/AaronSH123/Deep-Learning-Project

Estos recursos permiten la reproducción del pipeline, así como la posibilidad de extender el trabajo o adaptarlo a nuevos experimentos.

Agradecimientos

Los autores agradecen a la Pontificia Universidad Católica del Perú y al curso de Deep Learning (1INF52) por el apoyo académico proporcionado para la realización de este proyecto.

XI. Referencias

Referencias

[1] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li y P. J. Liu, "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer," *Journal of Machine Learning Research*, vol. 21, no. 140, pp. 1–67, 2020.

[2] Q. A. Itsnaini, M. Hayaty, A. D. Putra y N. A. M. Jabari, "Abstractive Text Summarization using Pre-Trained Language Model "Text-to-Text Transfer Transformer (T5),"" *ILKOM Jurnal Ilmiah*, vol. 15, no. 1, pp. 124–131, 2023. DOI: 10.33096/ilkom.v15i1.1532.124-131.

[3] Y. Huang, X. Feng, X. Feng y B. Qin, "The Factual Inconsistency Problem in Abstractive Text Summarization: A Survey," arXiv preprint arXiv:2104.14839, 2021.

[4] G. O. Nnadi y F. Bertini, "Survey on Abstractive Text Summarization: Dataset, Models, and Metrics," arXiv preprint arXiv:2412.17165, 2024.

[5] M. Raffel et al., "Architecture of the base version of the T5 model," ResearchGate, disponible en: https://www.researchgate.net/figure/Architecture-of-the-base-version-of-the-T5-model_fig4_385359944